Nota����o, teoria e compara����o de m��todos

vida-grupo-pricing

Sumário

Notação e teoria **1**

Símbolos gerais 1
1. Exposição e A/E (01, 02 — `exposicao`, `estudo`) 1
2. GLM de Poisson com offset (03a, 03b — `glmm`, R `stats::glm`) 2
3. Modelo misto (GLMM) (03b — R `glmmTMB`) 2
4. Penalização: elastic net, ridge e "priori" (03a, 03b — `elasticnet`, R `glmnet`) 2
4b. AGLM (03a, 03b — `aglm`, R `glmnet`) 3
4c. GAM (03a, 03b — `gam`, R `mgcv`) 3
5. LightGBM, SHAP e interações (03a, 03b — `diagnostico`) 3
6. Credibilidade (04, 05 — `renovacao`, R `actuar`) 3
7. Pooling e IBNR (04 — `renovacao`, `ibnr`) 4
8. Reajuste e cotação (04, 06 — `renovacao`, `cotador`) 4
9. Validação (03a, 03b, 05 — `avaliacao`, `backtest`) 4
10. Monitoramento (07 — `monitoramento`) 5
10b. Dados faltantes (01 — `exposicao`, `validacao`, `manual`) 5
11. Comparação dos métodos 5

Notação e teoria

Guia de referência dos símbolos e métodos do projeto, na ordem do pipeline. Cada seção diz **o que é**, **a fórmula** e **onde aparece** (notebook e módulo). A seção 11 compara os métodos (vantagens, desvantagens, quando usar).

Para gerar o PDF (LaTeX, via Quarto) a partir deste mesmo arquivo: `quarto render docs/notacao.md --to pdf`.

Símbolos gerais

Símbolo	Significado
x	idade (completa) da vida
q_x	probabilidade de morte em um ano na idade x (tábua BR-EMSmt 2026, por sexo)
t	fração do ano em que a vida esteve exposta (dias ÷ 365,25)
C	capital segurado da vida
C_{ref}	capital de referência (R$ 50 mil): só normaliza o fator de capital
c	célula de modelagem (grupo × faixa etária × sexo × faixa de capital) ou célula da SOA

Símbolo	Significado
g, i	grupo (estipulante); na credibilidade, i indexa grupos e j períodos
N	óbitos observados (contagem)
E	óbitos esperados pela tábua
μ	óbitos esperados por um modelo
A	observado (contagem ou valor), com IBNR quando indicado
P	nível de pooling do grupo
Z	credibilidade (peso da experiência própria)

1. Exposição e A/E (01, 02 — `exposicao`, `estudo`)

$$E = \sum_{\text{vidas}} q_x\, t, \qquad E^{(v)} = \sum_{\text{vidas}} q_x\, t\, C, \qquad \frac{A}{E} = \frac{N}{E}.$$

- **Vidas-ano** $= \sum t$; **capital-ano** $= \sum t\, C$.
- **Número efetivo de óbitos.** Com capitais diferentes, a variância do valor observado é $\sum C^2 qt$ (Poisson composta), e o A/E em valor tem a precisão de

$$n_{ef} = \frac{\left(\sum Cqt\right)^2}{\sum C^2 qt} \le E,$$

  com igualdade quando todos os capitais são iguais. É o peso da credibilidade em valor.
- **Intervalo exato de Poisson (Garwood)** para a média de uma contagem N, nível $1-\alpha$:

$$\left[\tfrac{1}{2}\chi^2_{\alpha/2}(2N),\ \tfrac{1}{2}\chi^2_{1-\alpha/2}(2N+2)\right],$$

  dividido por E para o A/E. Aproximação: A/E $\pm\, 1{,}96/\sqrt{N}$. Com 30 óbitos, cerca de ±36%: daí o mínimo de 30 esperados para um nível ter fator próprio.

2. GLM de Poisson com offset (03a, 03b — `glmm`, R `stats::glm`)

$$N_c \sim \text{Poisson}(\mu_c), \qquad \log \mu_c = \underbrace{\log E_c}_{\text{offset}} + \beta_0 + \sum_k \beta_k x_{ck}.$$

O offset fixa a tábua: cada e^{β_k} é um fator multiplicativo sobre ela.

- **Deviance:** $D = 2\sum_c \left[N_c \log \frac{N_c}{\mu_c} - (N_c - \mu_c)\right]$ (termo com $N_c = 0$ vale μ_c). Menor é melhor; é a medida de erro adequada a contagens de eventos raros.
- **AIC** $= 2p - 2\log L$, com p parâmetros. Só compara modelos ajustados aos mesmos dados.
- **ANOVA sequencial:** deviance explicada por cada variável, entrando na ordem da fórmula (tabela da SOA, seção 4.1).
- **Dispersão de Pearson** $= \sum (N-\mu)^2/\mu \,/\, (n-p)$: perto de 1 indica que a Poisson descreve a variância.
- **Razão de verossimilhança:** $LR = 2(\log L_1 - \log L_0) \sim \chi^2_{gl}$. Para testar uma variância de efeito aleatório (fronteira do espaço de parâmetros), $p = \frac{1}{2}P(\chi^2_1 > LR)$.
- **Correção de Holm** para m testes: ordenam-se os p-valores e $p^{adj}_{(k)} = \max_{j\le k} \min\{1, (m-j+1)\, p_{(j)}\}$. Controla a chance de algum falso positivo.

3. Modelo misto (GLMM) (03b — R `glmmTMB`)

$$\log \mu_c = \log E_c + \mathbf{x}_c'\beta + u_{g(c)} + v_{d(c)}, \qquad u_g \sim N(0, \sigma^2_{est}),\ v_d \sim N(0, \sigma^2_{div}).$$

- O efeito do estipulante u_g captura a mortalidade própria do grupo; a divisão CNAE v_d, dentro da seção, dá credibilidade a cada divisão em torno da sua seção (Ohlsson, 2008).
- **Previsão de grupo novo** (sem u_g observado): $\mathrm{E}[e^u] = e^{\sigma^2/2}$, não 1.
- **Ajuste singular:** variância estimada abaixo de 10^{-8}; o efeito é retirado e o modelo reajustado.

4. Penalização: elastic net, ridge e "priori" (03a, 03b — `elasticnet`, R `glmnet`)

$$\hat{\beta} = \arg\min_{\beta}\ -\frac{1}{n}\log L(\beta) + \lambda\left[\frac{1-\alpha}{2}\|\beta\|_2^2 + \alpha\|\beta\|_1\right].$$

- $\alpha = 1$: LASSO (zera coeficientes); $\alpha = 0$: ridge (encolhe todos). λ por validação cruzada (`lambda.min`: o de menor erro).
- **Ridge é uma priori normal.** Maximizar a verossimilhança penalizada por $\lambda\|\beta\|^2$ é achar a moda da posteriori com $\beta \sim N(0, \tau^2)$, $\lambda \propto 1/\tau^2$ (MAP). LASSO corresponde a uma priori de Laplace.
- **Priori de um estudo de mercado.** Colocando a forma do estudo no offset,

  $$\log \mu = \log E + \beta^{SOA} \log \tfrac{C}{C_{ref}} + \log f_s^{SOA} + b_0 + \delta \log \tfrac{C}{C_{ref}} + \gamma_s,$$

  a penalização encolhe (δ, γ_s) para zero, isto é, para o estudo. É a mesma lógica da credibilidade: λ alto → fica no estudo; dados abundantes → segue a carteira (SOA, 2024, seção 4.3.1, liga λ ao k de Bühlmann).

4b. AGLM (03a, 03b — `aglm`, R `glmnet`)

GLM regularizado com codificações que capturam não linearidade sem perder a forma de tabela (Fujita, Tanaka, Kondo e Iwasawa, 2020).

- **Variáveis O** (dummies ordinais): para uma variável com níveis ordenados $1, \dots, m$, $d_j^O(x) = \mathbb{1}\{x < j\}$, $j = 2, \dots, m$. O coeficiente β_j é o **salto** entre os níveis $j-1$ e j; com LASSO, $\beta_j = 0$ funde as duas faixas. É equivalente ao *fused lasso* ($\lambda \sum_j |\gamma_j - \gamma_{j-1}|$ sobre os efeitos de nível γ).
- **Variáveis L**: com nós $b_1 < \cdots < b_{m-1}$, $l_j(x) = |x - b_j|$, mais o próprio x. A contribuição $\sum_j \beta_j l_j(x)$ é uma curva **linear por partes e contínua**; β_j é a mudança de inclinação no nó b_j.
- No projeto: capital em variáveis L (9 nós nos quantis do log), faixa etária e porte em O, seção e sexo em dummies comuns, LASSO, e a forma da SOA no offset. A tabela de fatores guarda os nós e os coeficientes.

4c. GAM (03a, 03b — `gam`, R `mgcv`)

$$\log \mu = \log E + \beta_0 + f(\log C) + \mathbf{x}'\beta, \qquad f(z) = \sum_k \theta_k B_k(z),$$

com B_k uma base de splines e uma penalização de rugosidade $\lambda \int f''(z)^2\, dz$ escolhida por REML. Os **graus de liberdade efetivos** (edf) medem a complexidade usada: edf ≈ 1 é uma reta (no log, uma elasticidade constante). A penalização é uma priori gaussiana sobre a rugosidade (interpretação bayesiana de Wood, 2017).

5. LightGBM, SHAP e interações (03a, 03b — `diagnostico`)

- **Gradient boosting** com perda Poisson e valor inicial $\log E$: soma árvores que corrigem o log da taxa.
- **SHAP:** decomposição aditiva da previsão, $\log \mu(\mathbf{x}) = \log \mu_0 + \sum_j \phi_j(\mathbf{x})$; importância = média de $|\phi_j|$.
- **Tabela de interações (estilo EIX):** para cada divisão de uma árvore cujo nó pai divide por outra variável, o par (pai, filho) acumula o ganho do filho (*sumGain*), as observações do filho (*sumCover*) e a frequência.

6. Credibilidade (04, 05 — `renovacao`, R `actuar`)

Flutuação limitada (prática de mercado): $Z = \min\left(1, \sqrt{n/n_{full}}\right)$, com n em vidas-ano, $n_{full} = 20\,000$ e $Z = 0$ abaixo de 500.

Bühlmann-Straub. Grupo i, período j, razão observada X_{ij} (aqui, A/E em valor contra a taxa manual) e peso w_{ij} (aqui, n_{ef}). Com $w_i = \sum_j w_{ij}$, $\bar{X}_i = \sum_j w_{ij} X_{ij}/w_i$ e $\bar{X} = \sum_i w_i \bar{X}_i / w$:

$$\hat{s}^2 = \frac{\sum_i \sum_j w_{ij}(X_{ij} - \bar{X}_i)^2}{\sum_i (n_i - 1)}, \qquad \hat{a} = \frac{\sum_i w_i(\bar{X}_i - \bar{X})^2 - (I-1)\hat{s}^2}{w - \sum_i w_i^2 / w},$$

$$k = \frac{\hat{s}^2}{\hat{a}}, \qquad Z_i = \frac{w_i}{w_i + k}, \qquad \hat{X}_i = Z_i \bar{X}_i + (1 - Z_i)\,\mu.$$

s^2 é a variância dentro do grupo (ruído) e a a variância entre grupos (sinal). Se $\hat{a} \le 0$, $Z = 0$. Na renovação, o complemento μ é a própria taxa manual (A/E = 1). É a melhor previsão linear (Bayes linear) do risco do grupo.

7. Pooling e IBNR (04 — `renovacao`, `ibnr`)

- **Nível de pooling:** $P = \min\{\text{retenção}, \max(\text{piso}, m\,\bar{C})\}$, com $\bar{C}$ o capital médio do grupo. Na experiência entra $\min(C, P)$; o excesso esperado vira **encargo** cobrado de todos: $\sum q f \max(C - P, 0)$.
- **Chain ladder mensal** (carteira): fatores de desenvolvimento $f_j = \sum_i S_{i,j+1} / \sum_i S_{i,j}$ (volume), $\text{CDF}_j = \prod_{k \ge j} f_k$, proporção avisada $p_j = 1/\text{CDF}_j$.
- **Bornhuetter-Ferguson por grupo:** $\text{IBNR} = \sum_{\text{meses}} E_m^{\text{apriori}} (1 - p_{a(m)})$, com $a(m)$ a idade do mês de ocorrência na avaliação. Estável para grupos com poucos sinistros.
- **Fator de desenvolvimento da taxa manual:** média de $1/p_a$ sobre os sinistros avisados da experiência (cada um representa $1/p_a$ sinistros finais).

8. Reajuste e cotação (04, 06 — `renovacao`, `cotador`)

$$\text{prêmio puro} = \sum q\, f_{\text{manual}} \min(C, P) \cdot \text{fator} + \text{encargo}, \qquad \text{taxa comercial} = \text{taxa pura} \cdot \frac{1 + \text{margem}}{1 - \sum \text{carregamentos}},$$

$$\text{reajuste} = \text{clip}\left(\frac{\text{taxa comercial}}{\text{taxa vigente}} - 1,\ \text{piso},\ \text{teto}\right).$$

Na cotação de grupo novo, fator = 1. f_{manual} = A/E base × fator de seção × fator de divisão × $(C/C_{ref})^{\beta_{cap}}$.

9. Validação (03a, 03b, 05 — `avaliacao`, `backtest`)

- **Teste fora do tempo:** ajusta-se com dados até uma data e avalia-se no período seguinte; o teste só é usado no fim (CAS, 4.3).
- **Bootstrap pareado:** reamostram-se as unidades (estipulantes, seguradoras) com reposição e soma-se a diferença de deviance entre dois modelos; o IC de 95% são os percentis 2,5 e 97,5. "Significativa" = IC sem o zero.
- **Gráfico de quantis:** ordena-se pela relatividade prevista μ/E, faixas de igual E; previsto e observado por faixa (CAS 7.2.1).
- **Double lift:** ordena-se pela razão entre dois modelos; vence o que acompanha o observado (CAS 7.2.2).
- **Lorenz e Gini:** ordenando do menor para o maior risco previsto, x = parcela acumulada de E, y = parcela acumulada de N; Gini = 2 × área entre a diagonal e a curva (CAS 7.2.4).
- **A/M:** observado ÷ modelo por nível; desvios acima de ±5% a ±10% indicam ajuste ruim (SOA 2.4.5); aqui também o IC exato.
- **Gráfico de sinistralidade:** ordena-se pelo custo previsto ÷ prêmio atual; sinistralidade observada por faixa (CAS 7.2.3).
- **Estabilidade:** bootstrap por estipulante dos fatores da tarifa (CAS 6.4).
- **Regra de decisão:** menor deviance no teste; empatados (IC contém zero) resolvidos por uma ordem de preferência fixada antes.

10. Monitoramento (07 — `monitoramento`)

- **Limites da carteira:** sob "a taxa está certa", $N \sim \text{Poisson}(E)$; limites do A/E = quantis de $\text{Poisson}(E) \div E$, para 95% e 99,8% (funnel plot, Spiegelhalter 2005).
- **Limites dos grupos:** com mortalidade própria $u \sim$ Gama de média 1 e variância τ^2, $N \sim$ Binomial Negativa com média E e variância $E + \tau^2 E^2$. Estimador de momentos: $\hat{\tau}^2 = \max\left\{0,\ \sum\left[(N-E)^2 - N\right] / \sum E^2\right\}$.
- **IBNR nos meses recentes:** $N^{aj} = N/p_a$; os meses com $a \leq 3$ ficam fora do A/E móvel.

10b. Dados faltantes (01 — `exposicao`, `validacao`, `manual`)

- **Sexo ausente:** com p a proporção de homens do perfil, o esperado é

$$\mathrm{E}[q] = p\, q_x^M + (1-p)\, q_x^F,$$

  exato para o número esperado de óbitos, que é linear em p. p vem do nível mais fino com dados: grupo e faixa de 10 anos, grupo, seção CNAE e faixa, carteira; para a cotação de um grupo sem sexo, a tabela de fatores guarda a proporção da carteira por seção e faixa etária. A média 50/50 só é certa se $p = 0{,}5$.
- **Ausência informativa** (*missing not at random*): se a falta de sexo se concentra em certos grupos ou atividades, a ausência carrega informação. Por isso "ND" é um nível próprio nas células, testado como fator.
- **Nascimento ausente:** imputação pela idade de entrada mediana do grupo, com indicador. Excluir a vida retira exposição e enviesa o A/E; o indicador permite medir a sensibilidade.
- **Gradient boosting** (LightGBM) aceita valores ausentes nativamente: aprende para que lado da árvore mandá-los. É cômodo, mas implícito: o modelo pode usar "ausente" como substituto de outra coisa, sem que isso apareça. Além disso, o sexo entra pela tábua (no offset), e o esperado precisa dele de qualquer forma. A ASOP 23 pede que o tratamento seja explícito e documentado.

11. Comparação dos métodos

Método	Vantagens	Desvantagens	Quando usar
GLM de Poisson com offset	interpretável fator a fator; erro-padrão; padrão regulatório e de mercado; rápido	forma fixada pelo modelador; sem encolhimento para níveis raros	tarifa, quando há volume para os fatores
GLMM (efeitos aleatórios)	credibilidade automática para níveis e grupos; separa ruído de heterogeneidade	efeitos fixos são condicionais ao grupo (como taxa de grupo novo, podem prever pior); ajuste singular com pouca variância	estimar a variância entre grupos; atividades com muitos níveis
Ridge / elastic net	encolhe níveis raros; aceita priori via offset; LASSO seleciona variáveis	sem erro-padrão (estabilidade por bootstrap); lambda depende da validação cruzada	pouca experiência; muitos níveis; incorporar estudo de mercado
AGLM	não linearidade e fusão de faixas sem escolher bins à mão; continua sendo tabela	curvas podem não ser monótonas; mais parâmetros para explicar	variáveis contínuas ou ordenadas com forma desconhecida
GAM	forma suave e estimada; edf mostra se a forma linear basta	curva precisa ser tabulada para tarifa; menos direto de explicar	diagnóstico da forma de variáveis contínuas
LightGBM	captura interações e não linearidades sem especificar; aceita ausentes	não explicável fator a fator; exige regularização forte com eventos raros	referência de desempenho; busca de estrutura faltante
Credibilidade de mercado (raiz)	simples, conhecida no mercado	limiares arbitrários; ignora concentração de capital	comparação (*champion*)
Bühlmann-Straub	k estimado nos dados; peso pelo número efetivo; melhor previsão linear	supõe estrutura estável entre períodos; k incerto com poucos grupos	renovação
Chain ladder + Bornhuetter-Ferguson	padrão de mercado; BF estável para grupos pequenos	supõe padrão de aviso estável	IBNR da carteira e alocação por grupo