Notação, teoria e comparação de métodos

Precificação e renovação de Vida em Grupo

Projeto `vida-grupo-pricing`

Guia de referência dos símbolos e métodos do projeto, na ordem do pipeline. Cada seção diz o que é, a fórmula e onde aparece (notebook e módulo de `src/vgpricing`). A Seção 12 compara os métodos (vantagens, desvantagens e quando usar).

Sumário

1 Símbolos gerais **2**

2 Exposição e A/E **2**

3 GLM de Poisson com offset **2**

4 Modelo misto (GLMM) **3**

5 Penalização: elastic net, ridge e priori **3**
- 5.1 AGLM . . . 3
- 5.2 GAM . . . 4
- 5.3 LightGBM, SHAP e interações . . . 4

6 Credibilidade **4**

7 Pooling e IBNR **5**

8 Reajuste e cotação **5**

9 Validação **5**

10 Monitoramento **6**

11 Dados faltantes **6**

12 Comparação dos métodos **7**

1 Símbolos gerais

Símbolo	Significado
x	idade completa da vida
q_x	probabilidade de morte em um ano na idade x (tábua BR-EMSmt 2026, por sexo)
t	fração do ano em que a vida esteve exposta (dias ÷ 365,25)
C, C_{ref}	capital segurado; capital de referência (R$ 50 mil), que só normaliza o fator de capital
c	célula de modelagem (grupo × faixa etária × sexo × faixa de capital)
g, i, j	grupo (estipulante); na credibilidade, i indexa grupos e j períodos
N, E, μ	óbitos observados; esperados pela tábua; esperados por um modelo
A	observado (contagem ou valor), com IBNR quando indicado
P	nível de pooling do grupo
Z, k	credibilidade (peso da experiência própria) e constante de credibilidade

2 Exposição e A/E

Onde aparece: 01 e 02 — `exposicao`, `estudo`

$$E = \sum_{\text{vidas}} q_x\, t, \qquad E^{(v)} = \sum_{\text{vidas}} q_x\, t\, C, \qquad \text{A/E} = \frac{N}{E}. \tag{1}$$

Vidas-ano são $\sum t$ e **capital-ano**, $\sum tC$.

Número efetivo de óbitos. Com capitais diferentes, a variância do valor observado é $\sum C^2 qt$ (Poisson composta), e o A/E em valor tem a precisão de

$$n_{\text{ef}} = \frac{\left(\sum Cqt\right)^2}{\sum C^2 qt} \;\le\; E, \tag{2}$$

com igualdade quando os capitais são iguais. É o peso da credibilidade em valor.

Intervalo exato de Poisson (Garwood). Para a média de uma contagem N, ao nível $1-\alpha$:

$$\left[\tfrac{1}{2}\,\chi^2_{\alpha/2}(2N),\ \tfrac{1}{2}\,\chi^2_{1-\alpha/2}(2N+2)\right], \tag{3}$$

dividido por E para o A/E. Aproximação: $\text{A/E} \pm 1{,}96/\sqrt{N}$. Com 30 óbitos, cerca de ±36%: daí o mínimo de 30 esperados para um nível ter fator próprio.

3 GLM de Poisson com offset

Onde aparece: 03 e 04 — `glmm` (R `stats::glm`)

$$N_c \sim \text{Poisson}(\mu_c), \qquad \log \mu_c = \underbrace{\log E_c}_{\text{offset}} + \beta_0 + \sum_k \beta_k x_{ck}. \tag{4}$$

O offset fixa a tábua: cada e^{β_k} é um fator multiplicativo sobre ela.

- **Deviance:** $D = 2\sum_c \left[N_c \log(N_c/\mu_c) - (N_c - \mu_c)\right]$ (com $N_c = 0$, o termo vale μ_c). Menor é melhor; é a medida de erro adequada a contagens de eventos raros.

- **AIC** $= 2p - 2\log L$, com p parâmetros; só compara modelos ajustados aos mesmos dados.
- **ANOVA sequencial:** deviance explicada por cada variável, na ordem da fórmula (tabela da SOA, seção 4.1).
- **Dispersão de Pearson** $= \sum(N-\mu)^2/\mu \,/\, (n-p)$: perto de 1, a Poisson descreve a variância.
- **Razão de verossimilhança:** $LR = 2(\log L_1 - \log L_0) \sim \chi^2_{gl}$. Para uma variância de efeito aleatório (fronteira do espaço de parâmetros), $p = \frac{1}{2}P(\chi^2_1 > LR)$.
- **Correção de Holm** para m testes: com os p-valores ordenados, $p^{\text{adj}}_{(k)} = \max_{j\le k} \min\{1,\ (m-j+1)\, p_{(j)}\}$.

4 Modelo misto (GLMM)

Onde aparece: 04 — `glmm` (R `glmmTMB`)

$$\log \mu_c = \log E_c + \mathbf{x}_c^\top \boldsymbol{\beta} + u_{g(c)} + v_{d(c)}, \qquad u_g \sim N(0, \sigma^2_{\text{est}}), \quad v_d \sim N(0, \sigma^2_{\text{div}}). \tag{5}$$

- O efeito do estipulante u_g capta a mortalidade própria do grupo; a divisão CNAE v_d, dentro da seção, dá credibilidade a cada divisão em torno da sua seção (Ohlsson, 2008).
- **Grupo novo** (sem u_g observado): $\mathrm{E}[e^u] = e^{\sigma^2/2}$, não 1.
- **Ajuste singular:** variância estimada abaixo de 10^{-8}; o efeito é retirado e o modelo, reajustado.

5 Penalização: elastic net, ridge e priori

Onde aparece: 03 e 04 — `elasticnet` (R `glmnet`)

$$\hat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \ -\frac{1}{n}\log L(\boldsymbol{\beta}) + \lambda\left[\frac{1-\alpha}{2}\,\|\boldsymbol{\beta}\|_2^2 + \alpha\,\|\boldsymbol{\beta}\|_1\right]. \tag{6}$$

- $\alpha = 1$: LASSO (zera coeficientes); $\alpha = 0$: ridge (encolhe todos). λ por validação cruzada (`lambda.min`, o de menor erro).
- **Ridge é uma priori normal.** Maximizar a verossimilhança penalizada por $\lambda\|\beta\|^2$ é achar a moda da posteriori com $\beta \sim N(0, \tau^2)$, $\lambda \propto 1/\tau^2$. LASSO corresponde a uma priori de Laplace.
- **Priori de um estudo de mercado.** Com a forma do estudo no offset,

$$\log \mu = \log E + \beta^{\text{SOA}} \log \tfrac{C}{C_{\text{ref}}} + \log f_s^{\text{SOA}} + b_0 + \delta\, \log \tfrac{C}{C_{\text{ref}}} + \gamma_s, \tag{7}$$

  a penalização encolhe (δ, γ_s) para zero, isto é, para o estudo: λ alto mantém o estudo; dados abundantes seguem a carteira. A SOA (2024, seção 4.3.1) liga λ ao k de Bühlmann.

5.1 AGLM

Onde aparece: 03 e 04 — `aglm` sobre `glmnet`

GLM regularizado com codificações que captam não linearidade sem perder a forma de tabela (Fujita, Tanaka, Kondo e Iwasawa, 2020).

- **Variáveis O** (dummies ordinais): para níveis ordenados $1, \ldots, m$, $d^O_j(x) = \mathbb{1}\{x < j\}$, $j = 2, \ldots, m$. O coeficiente β_j é o salto entre os níveis $j-1$ e j; com LASSO, $\beta_j = 0$ funde as duas faixas. Equivale ao *fused lasso*, $\lambda \sum_j |\gamma_j - \gamma_{j-1}|$ sobre os efeitos de nível.

- **Variáveis L**: com nós $b_1 < \cdots < b_{m-1}$, $l_j(x) = |x - b_j|$, mais o próprio x. A contribuição $\sum_j \beta_j l_j(x)$ é linear por partes e contínua; β_j é a mudança de inclinação no nó b_j.
- No projeto: capital em variáveis L (9 nós nos quantis do log), faixa etária e porte em O, seção e sexo em dummies comuns, LASSO e a forma da SOA no offset.

5.2 GAM

Onde aparece: 03 e 04 — `gam` (R `mgcv`)

$$\log \mu = \log E + \beta_0 + f(\log C) + \mathbf{x}^\top \boldsymbol{\beta}, \qquad f(z) = \sum_k \theta_k B_k(z), \tag{8}$$

com B_k uma base de splines e penalização de rugosidade $\lambda \int f''(z)^2\, dz$, escolhida por REML. Os **graus de liberdade efetivos** (edf) medem a complexidade usada: edf ≈ 1 é uma reta (no log, uma elasticidade constante). A penalização é uma priori gaussiana sobre a rugosidade (Wood, 2017).

5.3 LightGBM, SHAP e interações

Onde aparece: 03 e 04 — `diagnostico`

- **Gradient boosting** com perda Poisson e valor inicial $\log E$: soma árvores que corrigem o log da taxa.
- **SHAP:** decomposição aditiva $\log \mu(\mathbf{x}) = \log \mu_0 + \sum_j \phi_j(\mathbf{x})$; importância = média de $|\phi_j|$.
- **Tabela de interações (estilo EIX):** cada divisão de uma árvore cujo nó pai divide por outra variável forma um par, que acumula o ganho do filho (*sumGain*), as observações do filho (*sumCover*) e a frequência.

6 Credibilidade

Onde aparece: 05 — `renovacao` (R `actuar`)

Flutuação limitada (prática de mercado). $Z = \min\left(1, \sqrt{n/n_{\text{full}}}\right)$, com n em vidas-ano, $n_{\text{full}} = 20\,000$ e $Z = 0$ abaixo de 500.

Bühlmann-Straub. Grupo i, período j, razão observada X_{ij} (A/E em valor contra a taxa manual) e peso w_{ij} (n_{ef}). Com $w_i = \sum_j w_{ij}$, $\bar{X}_i = \sum_j w_{ij} X_{ij}/w_i$ e $\bar{X} = \sum_i w_i \bar{X}_i / w$:

$$\hat{s}^2 = \frac{\sum_i \sum_j w_{ij}\,(X_{ij} - \bar{X}_i)^2}{\sum_i (n_i - 1)}, \qquad \hat{a} = \frac{\sum_i w_i\,(\bar{X}_i - \bar{X})^2 - (I-1)\,\hat{s}^2}{w - \sum_i w_i^2 / w}, \tag{9}$$

$$k = \frac{\hat{s}^2}{\hat{a}}, \qquad Z_i = \frac{w_i}{w_i + k}, \qquad \hat{X}_i = Z_i\,\bar{X}_i + (1 - Z_i)\,\mu. \tag{10}$$

s^2 é a variância dentro do grupo (ruído) e a a variância entre grupos (sinal). Se $\hat{a} \le 0$, ou se não há dois grupos com dois períodos, $Z = 0$. Na renovação, o complemento μ é a própria taxa manual (A/E = 1). É a melhor previsão linear (Bayes linear) do risco do grupo.

7 Pooling e IBNR

Onde aparece: 05 — `renovacao`, `ibnr`

- **Nível de pooling:** $P = \min\{\text{retenção},\ \max(\text{piso},\ m\,\bar{C})\}$, com $\bar{C}$ o capital médio do grupo. Na experiência entra $\min(C, P)$; o excesso esperado vira encargo cobrado de todos: $\sum q f \max(C - P, 0)$.
- **Chain ladder mensal** (carteira): fatores de desenvolvimento $f_j = \sum_i S_{i,j+1} / \sum_i S_{i,j}$, $\text{CDF}_j = \prod_{k \geq j} f_k$ e proporção avisada $p_j = 1/\text{CDF}_j$.
- **Bornhuetter-Ferguson por grupo:** $\text{IBNR} = \sum_{\text{meses}} E_m^{\text{apriori}} (1 - p_{a(m)})$, com $a(m)$ a idade do mês de ocorrência na avaliação; estável para grupos com poucos sinistros.
- **Fator de desenvolvimento da taxa manual:** média de $1/p_a$ sobre os sinistros avisados da experiência (cada sinistro avisado com idade a representa $1/p_a$ sinistros finais).

8 Reajuste e cotação

Onde aparece: 05 e 06 — `renovacao`, `cotador`

$$\text{prêmio puro} = \sum q\, f_{\text{manual}} \min(C, P) \cdot \text{fator} + \text{encargo}, \qquad \text{taxa comercial} = \text{taxa pura} \cdot \frac{1 + \text{margem}}{1 - \sum \text{carregamentos}}, \tag{11}$$

$$\text{reajuste} = \text{clip}\left(\frac{\text{taxa comercial}}{\text{taxa vigente}} - 1,\ \text{piso},\ \text{teto} \right), \tag{12}$$

com $f_{\text{manual}} = \text{A/E base} \times \text{fator de seção} \times \text{fator de divisão} \times (C/C_{\text{ref}})^{\beta_{\text{cap}}}$. Na renovação, fator $= Z\,\text{A/E} + (1 - Z)$; na cotação de grupo novo sem histórico, fator $= 1$.

Cotação com o histórico do grupo. A subscrição recebe, por ano j do histórico, os sinistros avisados até a data da cotação, S_j (limitados ao pooling), e o capital K_j. Com p_j a proporção do ano j que já deveria estar avisada (padrão de aviso da carteira) e c o custo esperado anual do censo na taxa manual,

$$\text{A/E}_{\text{hist}} = \frac{\sum_j S_j / p_j}{\sum_j c\, K_j / K}, \qquad n_{\text{ef}}^{\text{hist}} = n_{\text{ef}} \sum_j \frac{K_j}{K}, \qquad Z = \frac{n_{\text{ef}}^{\text{hist}}}{n_{\text{ef}}^{\text{hist}} + k}, \tag{13}$$

com o k de Bühlmann-Straub da carteira. Sem dividir por p_j, o último ano (incompleto) puxa a taxa para baixo.

9 Validação

Onde aparece: 03, 04, 05 e 06 — `avaliacao`, `backtest`

- **Teste fora do tempo:** ajusta-se com dados até uma data e avalia-se no período seguinte; o teste só é usado no fim (CAS, seção 4.3).
- **Bootstrap pareado:** reamostram-se as unidades (estipulantes, seguradoras) e soma-se a diferença de deviance entre dois modelos; o IC de 95% são os percentis 2,5 e 97,5. "Significativa" = IC sem o zero.
- **Gráfico de quantis:** ordena-se pela relatividade prevista μ/E, em faixas de igual E (CAS 7.2.1).

- **Double lift:** ordena-se pela razão entre dois modelos; vence o que acompanha o observado (CAS 7.2.2).
- **Lorenz e Gini:** do menor para o maior risco previsto, x é a parcela acumulada de E e y a de N; Gini $= 2\times$ a área entre a diagonal e a curva (CAS 7.2.4).
- **A/M:** observado $\div$ modelo por nível; desvios além de $\pm 5\%$ a $\pm 10\%$ indicam ajuste ruim (SOA 2.4.5); aqui também com IC exato.
- **Gráfico de sinistralidade:** ordena-se pelo custo previsto $\div$ prêmio atual (CAS 7.2.3).
- **Estabilidade:** bootstrap por estipulante dos fatores da tarifa (CAS 6.4).
- **Cotação com histórico:** grupos novos simulados como chegam à subscrição (censo e histórico avisado), comparados com o ano seguinte, que a cotação não vê.
- **Regra de decisão:** menor deviance no teste; empatados (IC contém zero) resolvidos por uma ordem de preferência fixada antes.

10 Monitoramento

Onde aparece: 06 — `monitoramento`

- **Limites da carteira:** sob "a taxa está certa", $N \sim \text{Poisson}(E)$; os limites do A/E são os quantis de Poisson(E) divididos por E, a 95% e 99,8% (funnel plot, Spiegelhalter, 2005).
- **Limites dos grupos:** com mortalidade própria $u \sim$ Gama de média 1 e variância τ^2, $N \sim$ Binomial Negativa com média E e variância $E + \tau^2 E^2$. Estimador de momentos: $\hat{\tau}^2 = \max\{0,\ \sum[(N-E)^2 - N] / \sum E^2\}$.
- **IBNR nos meses recentes:** $N^{\text{aj}} = N / p_a$; os meses com $a \leq 3$ ficam fora do A/E móvel.

11 Dados faltantes

Onde aparece: 01 — `exposicao`, `validacao`, `manual`

- **Sexo ausente:** com p a proporção de homens do perfil,

$$\mathrm{E}[q] = p\, q_x^M + (1-p)\, q_x^F, \tag{14}$$

  exata para o número esperado de óbitos, que é linear em p. p vem do nível mais fino com dados: grupo e faixa de 10 anos, grupo, seção CNAE e faixa, carteira; para cotar um grupo sem sexo, a tabela de fatores guarda a proporção da carteira por seção e faixa etária. A média 50/50 só é certa se $p = 0{,}5$.
- **Ausência informativa:** se a falta de sexo se concentra em certos grupos ou atividades, a ausência carrega informação; por isso "ND" é um nível próprio nas células, testado como fator.
- **Nascimento ausente:** imputação pela idade de entrada mediana do grupo, com indicador. Excluir a vida retira exposição e enviesa o A/E.
- **Gradient boosting** aceita ausentes nativamente, mas de forma implícita: o modelo pode usar "ausente" como substituto de outra coisa. Além disso, o sexo entra pela tábua (no offset). A ASOP 23 pede tratamento explícito e documentado.

12 Comparação dos métodos

Método	Vantagens	Desvantagens	Quando usar
GLM de Poisson com offset	interpretável fator a fator; erro-padrão; padrão regulatório e de mercado; rápido	forma fixada pelo modelador; não encolhe níveis raros	tarifa, com volume para os fatores
GLMM	credibilidade automática para níveis e grupos; separa ruído de heterogeneidade	efeitos fixos condicionais ao grupo (como taxa de grupo novo, podem prever pior); ajuste singular	estimar a variância entre grupos; atividades com muitos níveis
Ridge / elastic net	encolhe níveis raros; aceita priori via offset; LASSO seleciona variáveis	sem erro-padrão (estabilidade por bootstrap); λ depende da validação cruzada	pouca experiência; muitos níveis; usar estudo de mercado
AGLM	não linearidade e fusão de faixas sem escolher bins à mão; continua sendo tabela	curvas podem não ser monótonas; mais parâmetros para explicar	contínuas ou ordenadas com forma desconhecida
GAM	forma suave e estimada; edf mostra se a forma linear basta	curva precisa ser tabulada para tarifa	diagnóstico da forma de variáveis contínuas
LightGBM	capta interações e não linearidades sem especificar; aceita ausentes	não explicável fator a fator; exige regularização forte com eventos raros	referência de desempenho; busca de estrutura faltante
Credibilidade de mercado	simples, conhecida no mercado	limiares arbitrários; ignora concentração de capital	comparação (*champion*)
Bühlmann-Straub	k estimado nos dados; peso pelo número efetivo; melhor previsão linear	supõe estrutura estável entre períodos; k incerto com poucos grupos	renovação e cotação com histórico
Chain ladder + BF	padrão de mercado; BF estável para grupos pequenos	supõe padrão de aviso estável	IBNR da carteira, por grupo e do histórico na cotação

Referências

- Bühlmann, H.; Gisler, A. (2005). *A Course in Credibility Theory and its Applications*. Springer.
- Fujita, S.; Tanaka, T.; Kondo, K.; Iwasawa, H. (2020). *AGLM: A Hybrid Modeling Method of GLM and Data Science Techniques*.
- Goldburd, M.; Khare, A.; Tevet, D.; Guller, D. (2025). *Generalized Linear Models for Insurance Rating*, 2. ed. CAS Monograph 5.
- Ohlsson, E. (2008). Combining generalized linear models and credibility models in practice. *Scandinavian Actuarial Journal*.
- Society of Actuaries (2024). *A Predictive Analytics Framework: A Reusable Workflow for Experience Analysis*.
- Spiegelhalter, D. (2005). Funnel plots for comparing institutional performance. *Statistics in Medicine*.
- Wood, S. (2017). *Generalized Additive Models: An Introduction with R*, 2. ed. CRC Press.